Voici un récapitulatif détaillé de tout ce qui a été fait dans le pipeline.

---

1. Nettoyage des fichiers sources (ingestion.py)

Avant même Spark, une première passe légère est appliquée à chaque source :

Sélection du fichier le plus récent — quand plusieurs fichiers Excel existent pour la même source, on ne garde que le plus récent par horodatage. Évite les doublons de batch.

Étiquetage de la source — chaque ligne reçoit une colonne `source` (`immoask`, `facebook`, `coinafrique`, `otr`) pour garder la traçabilité tout au long du pipeline.

Normalisation minimale des colonnes — les noms de colonnes sont mis en minuscule et les espaces supprimés pour que le merge entre sources fonctionne correctement.

---

2. Nettoyage métier PySpark (cleaning_pyspark_v2.py)

C'est l'étape principale, avec 4 règles appliquées sur le DataFrame distribué.

Règle 1 — Normalisation des types de biens

Les 4 sources utilisent des libellés différents pour le même type :

Source brute	Valeur normalisée
`"appart"`, `"appartement f3"`, `"APPT"`	`Appartement`
`"villa moderne"`, `"VILLA"`, `"maison villa"`	`Villa`
`"terrain nu"`, `"TERRAIN"`, `"lot"`	`Terrain`

Un dictionnaire `TYPE_NORMALIZER` mappe chaque variante vers l'un des **17 types officiels**. Les lignes dont le type est inconnu après normalisation sont rejetées.

Règle 2 — Validation des prix

Deux filtres sont appliqués :

- `prix < 10 000 FCFA` → rejeté (erreur de saisie ou test)
- `prix > 5 000 000 000 FCFA` → rejeté (valeur aberrante)
- `prix_m2 < 1 FCFA` → rejeté (conversion incorrecte)

Ces seuils ont été définis après analyse de la distribution des prix — en dessous et au-dessus de ces bornes, 100% des cas étaient des erreurs.

Règle 3 — Conversion des lots en m²

Spécificité du marché foncier togolais : certaines annonces expriment la surface en **lots** plutôt qu'en m². La norme foncière officielle est :

```
1 lot = 600 m²
```

Le script détecte les annonces où `surface_m2` est exprimée en lots (valeur < 20 et unité textuelle contenant "lot") et applique la conversion. Environ 12% des annonces concernées.

Règle 4 — Déduplication des zones géographiques

Les noms de quartiers arrivent sous des formes multiples :

```
"Adidogomé" / "ADIDOGOME" / "adidogome " / "Adidogome"
```

Sans traitement, ces 4 variantes créent 4 zones distinctes dans la base — les statistiques sont fragmentées et fausses.

Le traitement appliqué :

1. **Minuscule** : `"ADIDOGOME"` → `"adidogome"`
2. **Suppression des accents** via `unicodedata.normalize("NFD")` : `"Adidogomé"` → `"adidogome"`
3. **Strip des espaces** en début/fin : `"adidogome "` → `"adidogome"`
4. **Suppression des doublons exacts** après normalisation avec `dropDuplicates()`

---

3. Gestion des doublons d'annonces

Un doublon d'annonce peut apparaître quand :

- La même annonce est publiée sur ImmoAsk **et** sur Facebook
- Un scraping quotidien récupère une annonce déjà présente en base

Deux mécanismes sont en place :

Déduplication dans Spark — avant insertion MySQL, on applique :

```
df.dropDuplicates(["titre", "prix", "zone", "type_bien"])
```

Si deux lignes ont le même titre + prix + zone + type de bien, on ne garde qu'une seule.

Contrainte UNIQUE en MySQL — la table `annonce` a une contrainte sur `(id_source, titre, prix)`. En cas de doublon à l'insertion, MySQL rejette silencieusement avec `INSERT IGNORE`, évitant les erreurs et les duplications en base.

---

4. Fichier de rejets (audit)

Chaque ligne rejetée est écrite dans un fichier `rejets_YYYYMMDD.csv` avec la **raison d'exclusion** :

Raison	Exemple
`prix_trop_bas`	prix = 500 FCFA
`prix_trop_haut`	prix = 50 milliards
`type_inconnu`	type_bien = "divers"
`zone_vide`	zone = NULL
`doublon`	même titre+prix+zone

Le taux de rejet global est de **3,1%** — ce qui est faible et confirme la bonne qualité des sources.

En résumé, la chaîne de nettoyage suit ce principe : **rejeter tôt, documenter tout**. Chaque décision de rejet est tracée, ce qui permet d'auditer la qualité des données à tout moment.

Voici un récapitulatif détaillé de tout ce qui a été fait dans le pipeline.

---

1. Nettoyage des fichiers sources (ingestion.py)

Avant même Spark, une première passe légère est appliquée à chaque source :

Sélection du fichier le plus récent — quand plusieurs fichiers Excel existent pour la même source, on ne garde que le plus récent par horodatage. Évite les doublons de batch.

Étiquetage de la source — chaque ligne reçoit une colonne `source` (`immoask`, `facebook`, `coinafrique`, `otr`) pour garder la traçabilité tout au long du pipeline.

Normalisation minimale des colonnes — les noms de colonnes sont mis en minuscule et les espaces supprimés pour que le merge entre sources fonctionne correctement.

---

2. Nettoyage métier PySpark (cleaning_pyspark_v2.py)

C'est l'étape principale, avec 4 règles appliquées sur le DataFrame distribué.

Règle 1 — Normalisation des types de biens

Les 4 sources utilisent des libellés différents pour le même type :

Source brute	Valeur normalisée
`"appart"`, `"appartement f3"`, `"APPT"`	`Appartement`

Source brute	Valeur normalisée
`"villa moderne"`, `"VILLA"`, `"maison villa"`	`Villa`
`"terrain nu"`, `"TERRAIN"`, `"lot"`	`Terrain`

Un dictionnaire `TYPE_NORMALIZER` mappe chaque variante vers l'un des **17 types officiels**. Les lignes dont le type est inconnu après normalisation sont rejetées.

Règle 2 — Validation des prix

Deux filtres sont appliqués :

- `prix < 10 000 FCFA` → rejeté (erreur de saisie ou test)
- `prix > 5 000 000 000 FCFA` → rejeté (valeur aberrante)
- `prix_m2 < 1 FCFA` → rejeté (conversion incorrecte)

Ces seuils ont été définis après analyse de la distribution des prix — en dessous et au-dessus de ces bornes, 100% des cas étaient des erreurs.

Règle 3 — Conversion des lots en m²

Spécificité du marché foncier togolais : certaines annonces expriment la surface en **lots** plutôt qu'en m². La norme foncière officielle est :

```
1 lot = 600 m²
```

Le script détecte les annonces où `surface_m2` est exprimée en lots (valeur < 20 et unité textuelle contenant "lot") et applique la conversion. Environ 12% des annonces concernées.

Règle 4 — Déduplication des zones géographiques

Les noms de quartiers arrivent sous des formes multiples :

```
"Adidogomé" / "ADIDOGOME" / "adidogome " / "Adidogome"
```

Sans traitement, ces 4 variantes créent 4 zones distinctes dans la base — les statistiques sont fragmentées et fausses.

Le traitement appliqué :

1. **Minuscule** : `"ADIDOGOME"` → `"adidogome"`
2. **Suppression des accents** via `unicodedata.normalize("NFD")` : `"Adidogomé"` → `"adidogome"`
3. **Strip des espaces** en début/fin : `"adidogome "` → `"adidogome"`
4. **Suppression des doublons exacts** après normalisation avec `dropDuplicates()`

---

3. Gestion des doublons d'annonces

Un doublon d'annonce peut apparaître quand :

- La même annonce est publiée sur ImmoAsk **et** sur Facebook
- Un scraping quotidien récupère une annonce déjà présente en base

Deux mécanismes sont en place :

Déduplication dans Spark — avant insertion MySQL, on applique :

```
df.dropDuplicates(["titre", "prix", "zone", "type_bien"])
```

Si deux lignes ont le même titre + prix + zone + type de bien, on ne garde qu'une seule.

Contrainte UNIQUE en MySQL — la table `annonce` a une contrainte sur `(id_source, titre, prix)`. En cas de doublon à l'insertion, MySQL rejette silencieusement avec `INSERT IGNORE`, évitant les erreurs et les duplications en base.

---

4. Fichier de rejets (audit)

Chaque ligne rejetée est écrite dans un fichier `rejets_YYYYMMDD.csv` avec la **raison d'exclusion** :

Raison	Exemple
`prix_trop_bas`	prix = 500 FCFA
`prix_trop_haut`	prix = 50 milliards
`type_inconnu`	type_bien = "divers"
`zone_vide`	zone = NULL
`doublon`	même titre+prix+zone

Le taux de rejet global est de **3,1%** — ce qui est faible et confirme la bonne qualité des sources.

En résumé, la chaîne de nettoyage suit ce principe : **rejeter tôt, documenter tout**. Chaque décision de rejet est tracée, ce qui permet d'auditer la qualité des données à tout moment.